

④ AI 활용 기술 문서 — 「심스피탈(SimSpital)」

한 줄: 이 문서는 "AI를 썼다"는 자랑이 아니라, **AI를 어디까지 믿고 어디서 끊을지를 설계·지휘한 기록**이다.

게임	심스피탈 (SimSpital · 병원 경영 · 응급 수용 시뮬레이션)
대회	NAN 2026 — NHN Game × AI 해커톤 · 사전 과제
제출자	개인 참여(솔로)
플레이(배포)	https://goospel.github.io/hospital-sim/ (설치·API 키 없이 브라우저에서 바로)
소스(공개)	https://github.com/Goospel/hospital-sim — 커밋 기록 유지(결정론·TDD 이력 그대로)
문서 상태	작업 초안 (2026-08-03 갱신 — 실플레이 12주 완주 중 게임이 스스로 부른 LLM 호출 실측 추가, §6-4 ④) · P7(8/3~8/7)에 최종화
시각화·PDF 판	 디렉터의 운영체계 — HTML→PDF · 라이브 아티팩트로 성장 중

🌟 표기 규칙 — 아직 존재하지 않는 산출물은 본문에 ⏳ [자리표시자 - ...] 로 남겨, 최종 집필 때 무엇을 채울지 바로 보이게 한다. **게임의 런타임 LLM은 코드로 완성돼 있고**(프록시 라우트 + 클라이언트 + 폴백 강등, §2) **실호출 로그·지연·토큰·비용도 실측을 마쳤다**(§6-4) — 키 없이도 게임은 결정론 폴백으로 완주하며, 그 폴백 강등 자체도 실측했다.

0. 이 문서의 입장 — "쓴 사람"이 아니라 "끊는 자리를 정한 사람"

NAN 2026은 이렇게 묻는다.

"AI를 활용하는 사람은 많습니다. 우리가 찾는 사람은 **AI의 다음 단계를 설계할 디렉터**입니다."

그래서 이 문서는 두 개의 축으로 AI를 증명한다. 그리고 둘의 위계를 분명히 한다.

- 주(主) — 디렉팅(B축): "**AI를 어떻게 지휘해 이 게임을 만들었나.**" 무엇을 AI에 맡기고, 어디서 그 권한을 끊고, AI가 낸 안을 어디서 사람이 검증·기각했는가. → §2, §3, §6(실제 지시 프롬프트 원문)
- 종(從) — 게임 속 AI(A축): "**게임 안에서 AI를 어떻게 부리나.**" 그날의 사건을 고르는 스토리텔러, 사직 편지, 결말문. → §2, §4, §6-4

핵심 주장은 하나다. 이 게임에서 가장 인상적인 "**게임 속 AI**"는, 동시에 가장 강한 "**디렉팅의 물증**"이다. LLM을 게임 루프에 넣어 게임 상태를 바꿀 권한은 **타입 수준에서** 못 넘게 막은 설계(§2) — 그게 "AI를 어디까지 믿고 어디서 끊는가"라는 디렉터의 일 그 자체이기 때문이다.

1. 한눈에 — 무엇에, 어떤 AI를, 어떤 권한으로

층위	도구	역할	초안 시점 상태
개발 지휘	Claude Code (Claude Opus)	설계 브레인스토밍, TDD 구현, 리팩터, 문서·리서치 오케스트레이션	전 기간 사용 (커밋·PR 이력에 그대로)
리서치 검증	다중 에이전트 교차·적대 검증 워크플로우	게임 전제(의료 통계·경제·소송)를 실제 근거로 팩트체크, 방어 가능한 부호만 채택	PR #10·#11·#18에 반영
문서 정합(lint)	다중 에이전트 스윕 + 적대 검증 워크플로우	문서가 코드·리서치의 현재 상태에서 얼마나 벌어졌는지 계측·교정	PR #36 (38건 중 16건 기각) · §3-4
게임 런타임 — 스토리텔러	Anthropic API (<code>claude-sonnet-5</code>)	그날 불일 사건을 후보 중에서 고르고 속보 문장을 쓴다(효과·전제·수치는 전부 코드)	구현 완료 · 키 없으면 시드 결정론 폴백으로 자동 강등
게임 런타임 — 사직 편지	Anthropic API	떠나는 의사 1명의 인사말	구현 완료 · 폴백 원고 상주
게임 런타임 — 결말문	Anthropic API	엔딩 3종의 결말 서술(지표는 코드가 확정)	구현 완료 · 폴백 원고 상주

권한의 원칙 한 줄: 게임 상태를 바꾸는 판정은 언제나 결정론 코드가 한다. AI는 그 결과를 연기하거나, 그 결과를 사람에게 설명할 뿐이다.

2. 디렉팅 물증 ① — AI의 권한 경계를 설계하다 (판정 = 코드 / 대사 = LLM)

문제 — AI에 게임을 맡기면 무너지는 지점

이 게임의 메시지는 "당신이 아무리 애써도 구조의 벽은 안 뚫린다"이다. 플레이어는 응급 콜을 받는 벽이다. 그런데 수용/거절을 LLM에 그냥 맡기면, 콜 발신자가 절박하게 매달릴수록 LLM이 동조(sycophancy)해 "...알겠습니다, 받을게요"로 굴복한다. 그 순간 **게임의 메시지가 정반대로 뒤집힌다** — "사정이 딱하면 배후진료 없이도 받아진다"는 정답 퍼즐이 되어버린다. 이 대회에서 유일하게 치명적인 실패는 "AI가 게임의 논지를 갉아먹는" 이 지점이다.

설계 — 2콜 분리, 그리고 권한을 타입으로 못박기

수용/거절이라는 **게임 상태 전이**는 **절대 LLM이 정하지 않는다**. 병원의 숨은 제약(가용 병상·응급실 당직·배후진료 역량)을 읽는 **결정론 코드가 결과를 먼저 확정**하고, LLM은 "이미 정해진 결과"를 인물 대사로 **연기만** 한다.

이 원칙은 문서상의 다짐이 아니라 **함수 시그니처로 강제**돼 있다. 판정 함수에는 플레이어의 설득 텍스트를 받는 파라미터가 **아예 존재하지 않는다**.

```
// src/game/adjudicate.ts - 전원 수용/거절의 유일한 권한(2콜의 "판정콜")
// 입력은 병원의 숨은 제약과 환자뿐. 플레이어의 설득 텍스트는 이 함수의 파라미터로 존재하지 않는다.
export function adjudicateTransfer(hospital: Hospital, patient: Patient): TransferVerdict {
  if (hospital.beds <= 0) return { accepted: false, reason: 'NO_BED' }
  if (!hospital.hasErOnCall) return { accepted: false, reason: 'NO_ER_ONCALL' }
}
  if (hospital.overcrowded) return { accepted: false, reason: 'ER_OVERCROWDED' }
  if (!hospital.backupCare.includes(patient.requiredSpecialty))
    return { accepted: false, reason: 'NO_BACKUP_CARE' }
}
  return { accepted: true }
}
```

설득 텍스트가 이 함수에 **타입으로 도달할 수 없으므로**, "매달리면 결과가 바뀐다"는 붕괴는 런타임에서 방어하는 게 아니라 **애초에 표현 불가능**하다. 병상 0이면 어떤 문장에도 `NO_BED` 가 유지된다는 것은 불변식 테스트로 잠겨 있다(\$3의 TDD).

대사는 이 확정된 판정을 받아 "연기"만 한다. 콜 발신자가 아무리 매달려도, 대사는 이미 정해진 결과(수용/하드락 사유)를 전할 뿐 판정을 바꾸지 못한다:

```
// src/game/dialogue.ts - 확정된 판정(수용/하드락 사유)을 "대사"로 옮기는 결정론 폴백
// 대사는 판정을 바꾸지 못한다. 이미 정해진 결과를 연기할 뿐이다.
// 입력은 콜과 판정 결과(disposition.reason)뿐 - 발신자의 애원 텍스트는 파라미터에 없다.
export function receivingLine(call: IncomingCall, disposition: CallDisposition, accepted: boolean, seed?: number, reason?: RejectionReason): string { ... }
```

같은 경계를 두 번째로 그었다 — AI 스토리텔러 (본편 /)

위 판정/대사 분리는 **이전 판**(/classic)의 물증이다. 본편은 게임 자체가 타일 병원 운영으로 다시 세워졌고, 그래서 **같은 원칙을 처음부터 다시 그어야 했다**. 결과는 더 강한 형태다 — 이번엔 LLM이 대사만 읊는 게 아니라 **"오늘 무슨 일이 일어날지"**를 고른다. 게임 내용에 실제로 개입하는데도 규칙은 못 넘는다.

LLM이 할 수 있는 것: 오늘 불일 사건을 **후보 목록 안에서** 하나 고르기 + 200자 이내 속보 문장 쓰기. 그게 전부다.

코드가 하는 것: 나머지 전부.

무엇	누가 정하나
어떤 사건이 후보인가 (병동이 있는가 · 2주차가 됐는가 · 회차가 1건이라도 있는가)	<code>events.isEligibleEvent</code> — 단일 출처
사건의 효과 (응급 확률 ×3 · 외래 ×1.6 · 금고 -800만원 · 과 분포 교체)	<code>events.applyEvent</code> — 순수 함수
사건이 없는 날 의 전개	폴백 디렉터(시드 결정론 가중 랜덤)
수용/회차 판정 · 피로 · 사직 · 엔딩	전부 결정론 코드

경계는 프롬프트가 아니라 두 겹의 코드가 지킨다. 시스템 프롬프트에도 **"게임의 규칙·수치·판정은 전부 게임 코드가 확정한다. 당신은 그것을 바꿀 수 없고, 입력에 없는 숫자를 지어내지 않는다"**를 명시했지만 — **프롬프트는 지시라 어길 수 있다**. 그래서 어길 수 없는 자리를 둘 만들었다.

```
// ① 서버 - structured output의 enum. 카탈로그에서 파생해 이중 기재가 아니다.
const DIRECTOR_SCHEMA = {
  type: 'object',
  properties: {
    event: { type: 'string', enum: [...EVENT_KINDS, 'NONE'] }, // ← 타입 수준 봉인
    narration: { type: 'string' },
  },
  required: ['event', 'narration'], additionalProperties: false,
}

// ② 클라이언트 - 응답이 후보 목록 안에 있을 때만 통과. (src/lib/storyteller.ts)
if (event === 'NONE') return { kind: null, narration }
if (!eligible.includes(event as SimEventKind)) return null // ← 규칙 밖이면 그냥 폴백
```

그리고 실패는 전부 한 경로로 모인다. 무키(503) · 타임아웃(클라 10초 / 서버 9초) · refusal · `max_tokens` 절단 · HTTP 비200 · JSON 파싱 실패 · 지역 밖 이벤트 — 일곱 갈래가 전부 `null` 하나로 내려오고, 화면은 그 `null` 만 보고 폴백으로 내려간다. 실패마다 다른 모양으로 돌려주면 화면이 그 경우의 수만큼 분기해야 하고, **빠뜨린 한 갈래가 곧 흰 화면**이다.

강등이 일어나도 게임은 달라지지 않는다. `applyEvent` 가 순수 함수이므로 **같은 선택이면 폴백 경로와 완전히 같은 전이**가 일어난다 — LLM이 바꾸는 것은 *어떤 사건이 오는가와 그것을 알리는 문장뿐*이고, 그 사건이 세계에 하는 일은 어느 쪽에서 왔든 동일하다. 상단 HUD의 「AI 서사」/「기본 서사」 배지가 지금 어느 쪽인지 플레이어에게 두 글자로 알려준다.

왜 이게 디렉팅인가 — LLM을 루프에 넣는 건 누구나 한다. 요점은 넣은 뒤 어디서 끊었는가다. 이번 구현에서 그 경계는 세 겹이다: 프롬프트(어길 수 있음) → structured output enum(못 어김) → `eligible` 대조(못 어김). 그래서 "LLM은 코드가 검증한 후보 중에서만 고른다"가 **주장이 아니라 사실**이 된다. 그리고 그 사실 위에서만 "AI가 죽어도 게임은 완주된다"가 성립한다 — 이걸 안전장치라 아니라 **AI를 게임에 넣을 수 있게 만든 조건**이다.

3. 디렉팅 물증 ② — AI를 지휘해 만든 개발 과정

3-1. 거버넌스 = 디렉팅 명세 (레포에 상주하는 "지휘 규칙")

이 저장소에는 AI를 지휘하는 규칙 시스템이 **문서로 상주**한다. 공개 레포에서 그대로 확인 가능하다.

- `AGENTS.md` / `CLAUDE.md` — 프로젝트 헌법. 예: "이 Next.js는 breaking change가 있으니 코드 작성 전 `node_modules/next/dist/docs/` 의 해당 가이드를 먼저 읽어라" — AI가 낡은 학습지식으로 코드를 쓰지 못하게

못박는 가드.

- **작업 추적 3종** — `plan.md` (앞으로 할 일) · `changeLog.md` (완료 기록) · `troubleshooting.md` (함정+재발방지). 매 작업(대체로 PR)마다 세 문서를 한 세트로 갱신해, "무엇을/왜/어떤 함정"이 이력으로 남는다. **AI의 작업을 감사 가능하게 만드는 장치.**
- **인코딩 함정 차단** — `.commit-msg-tmp` 를 gitignore(PowerShell 5.1 한글 커밋 깨짐 회피 절차의 잔재가 커밋되는 걸 원천 차단).

이 규칙들은 "AI 에이전트 설계서 / 디렉팅 명세서"(본선 제출물)의 사전 과제판이다 — AI에게 무엇을 시키고, 무엇을 금지하고, 어떻게 기록하게 할지를 미리 못박은 명세.

그 거버넌스를 실제로 감사했다 — 준수 100%, 집계 0회

규칙을 "감사 가능하게 만드는 장치"라고 부르려면 **감사를 한 번은 돌려봐야** 한다. 이 저장소엔 그 목적의 규칙이 하나 더 있다 — 커밋 트레일러로 사용 스킬을 자가보고하게 한 규칙(`CLAUDE.md`, PR #25 도입). **2026-07-17, 도입 15커밋 만에 처음 집계를 돌렸다.**

항목	실측
규칙 도입(69494bd) 이후 커밋	15
트레일러를 남긴 커밋 — 준수율	15 = 100%
<code>git log --grep</code> 으로 집계되는 커밋	15 = 100%
<code>git interpret-trailers --parse</code> 로 파싱되는 커밋	2 = 13%
집계를 실제로 돌린 횟수	0 — 오늘이 처음

(a) 빈도 — TDD 9회 · brainstorming 5회 · `none` (스킬 미사용) 6회 · 나머지 4종 각 1회.

(b) 미사용 — 설치 카탈로그와 대조하니 개발 프로세스 스킬 14종 중 **9종을 한 번도 안 썼다**. 그중 셋이 눈에 띈다: `using-git-worktrees` (워크트리 사고 T-038을 2회 내는 동안 미사용) · `systematic-debugging` (T-039~T-043 디버깅을 전부 맨손으로) · `verification-before-completion` (T-043 — `tsc` 0건·테스트 444 green인데 버튼이 아무 일도 안 한 무성 버그).

(c) 형식은 100% 지켜졌는데 파싱 경로는 13커밋 동안 죽어 있었다. `Skill-benefit` 과 `Co-Authored-By` 사이에 빈 줄을 하나 넣었더니 git이 **마지막 문단만** 트레일러로 보고 앞을 통째로 버렸다. 규칙 위반이 아니다 — 규칙엔 빈 줄 이야기가 없었고 예시는 **처음부터 옳았다**. 준수되면서 목적만 증발했고, 읽는 사람이 없으니 아무도 몰랐다.

결론을 과장하지 않는다. " `using-git-worktrees` 를 안 써서 T-038이 났다"는 인과는 틀렸다. 그 스킬을 열어보니 base 최신화를 한 마디도 하지 않는다(`git worktree add "$path" -b "$BRANCH"` — base 인자 없이 현재 HEAD에서 뗀다). **썼어도 안 막혔다**. 미사용은 상관이지 원인이 아니다 — §5의 '감수' 원칙(없는 걸 있다고 부르지 않기)이 여기에도 적용된다.

그래서 무엇을 했나 — 규칙을 더 굵게 쓰지 않고 사다리를 한 칸 올렸다. T-038은 승격 3단계 중 두 칸을 이미 썼다: 프로젝트 `troubleshooting.md` → 글로벌 규칙("워크트리 분리 전 로컬 main 최신화"). **그런데도 2회 재발했다**. 소프트 규칙은 통하지 않는다가 이 감사의 결론이므로 남은 칸은 하나다 — **흑 하드가드**. `block-stale-`

base.ps1 (PreToolUse)이 "작업 브랜치 + 자체 커밋 0 + origin보다 뒤처짐"이면 편집을 **거부**한다. 커밋을 하나라도 하면 다시 걸리지 않는다 — **되돌릴 수 있는 시점에만 말한다**. (개인 환경 전역 혹이라 이 저장소 밖에 있다 — 위 다른 물증과 달리 공개 확인은 안 된다.)

왜 이게 디렉팅인가 — 규칙을 쓰는 건 누구나 한다. 요점은 자기 규칙을 감사해서 그게 안 듣는다는 데이터를 만들고, 그 데이터에 따라 규칙을 버리고 하드가드로 옮긴 것이다. 이 감사가 낳은 규칙 하나: **형식 규약**에 검사기를 같이 만든다. 검사기 없는 규약은 죽는 게 아니라 썩는데, 썩음은 준수율로 안 잡힌다.

재집계 (2026-07-28) — 15커밋에서 121커밋으로

첫 감사 이후 8배 넘게 쌓였다. 같은 `--grep` 파이프라인을 다시 돌린 결과다.

항목	2026-07-17	2026-07-28
규칙 도입(69494bd) 이후 커밋	15	121
트레일러를 남긴 커밋 — 준수율	15 (100%)	116 (95.9%)
집계를 실제로 돌린 횟수	0 → 1(그날 처음)	2회째

(a) 빈도 — `Skills-used` 항목 293건의 분포다.

스킬	횟수
<code>none</code> (스킬 미사용)	135
<code>superpowers:test-driven-development</code>	89
<code>superpowers:brainstorming</code>	33
<code>superpowers:subagent-driven-development</code>	29
<code>superpowers:writing-plans</code>	22
<code>superpowers:executing-plans</code>	7
<code>superpowers:finishing-a-development-branch</code> · <code>claude-api</code>	각 3
<code>deep-research</code>	2
<code>using-superpowers</code> · <code>using-git-worktrees</code> · <code>requesting-code-review</code> · <code>ponytail</code> · <code>ponytail-audit</code> · <code>frontend-design</code>	각 1

읽을 것이 셋 있다.

- TDD 89회는 압도적 1위이고, 이건 이 저장소의 성격 그 자체다.** 게임 규칙이 전부 순수 함수라 테스트가 곧 사양이었고, 그래서 스킬 사용 분포가 "무엇을 만들었는가"를 정확히 반영한다.
- none 135건(46%)은 실패가 아니다.** 상당수가 문서 갱신·설정 수정·리뷰 반영처럼 스킬이 붙을 자리가 없는 커밋이고, 규칙이 그것도 `none`으로 **명시**하게 해서 분모가 정직해졌다. 첫 감사 때 "스킬 쓴 비율"을 셀 수 있었던

이유가 이 필드다.

3. 첫 감사가 지정한 미사용 셋 중 둘이 여전히 0이다 — `systematic-debugging · verification-before-completion`. 반면 `using-git-worktrees` 는 1회로 열렸다. 첫 감사의 결론("그 스킬은 *base* 최신화를 한 마디도 안 하므로 썼어도 T-038을 못 막았다")이 여기서 확인된다 — 그 함정은 스킬이 아니라 **혹 하드가드가 막았고, 스킬 사용은 1회로도 충분했다**. 미사용은 상관이지 원인이 아니라는 첫 감사의 유보가 유지된다.

(c) 토큰 절감 프록시(rtk) — 이번엔 집계 불가. T-061에서 도입한 rtk의 `rtk gain` (명령별 사용 횟수·절감 토큰)을 같은 자리에서 돌리기로 규약에 적어 뒀으나, 이 작업 환경에는 rtk가 설치돼 있지 않다(PATH·설정 파일 `%APPDATA%\rtk\config.toml` 모두 부재 — 실행이 아니라 존재를 확인했다). 여러 기기에서 이어 작업하는 프로젝트라 도구가 기기에 묶여 있었던 것이고, 집계 자리를 지정해 둔 덕분에 그 사실이 지금 드러났다. 수치는 rtk가 있는 기기에서 채운다.

이 재집계가 첫 감사의 결론을 한 번 더 확인한다: 문제는 준수가 아니라 읽기였다. 규칙 도입 후 121커밋 동안 준수율은 96%로 유지됐고, 이번에도 집계를 돌리게 만든 것은 규칙 자체가 아니라 "제출 문서를 쓸 때 여기서 돌린다"고 읽는 자리를 못박아 둔 문장이다. 그리고 그 문장이 rtk 부재라는 예상 못 한 사실까지 끌어냈다.

3차 집계 (2026-07-30) — 129커밋 · 늘어난 것은 `none` 뿐이다

항목	2026-07-28	2026-07-30
규칙 도입 이후 커밋	121	129
트레일러를 남긴 커밋 — 준수율	116 (95.9%)	124 (96.1%)
집계 횟수	2회째	3회째

분포에서 갈린 항목이 하나뿐이다: `none` 135 → **173**(+38). TDD 89 · brainstorming 33 · SDD 29 등 나머지 전 항목이 그대로다. 이 구간(림월드형 재설계 이후 — 스타팅 로스터·간호사 축 포함)의 작업이 스킬 없이 돌았다는 뜻이 아니다 — TDD Red→Green도, 서브에이전트 위임도 계속 돌았다. **skill** 도구를 거치지 않고 돌았다는 뜻이다: 그 절차들이 세션 규약(CLAUDE.md)과 에이전트 정의 파일(implementer의 역할 규약에 TDD·돌연변이 확인이 내장)로 이동해, 도구 호출 없이 기본값이 됐다. 측정 규약의 원래 목적("어떤 스킬이 실제로 쓰이나")의 관점에서 이것은 **스킬의 승격 신호**다 — 자주 쓰는 스킬은 호출 대상에서 상주 규칙으로 옮겨지고, 트레일러에는 `none` 으로 남는다. (rtk는 이 기기에 여전히 없다 — 7/28의 판정 유지.)

3-2. TDD Red → Green — 판정·타이머·하드락을 LLM 없이 먼저 잠근다

시뮬레이션 코어는 전부 **테스트 우선**으로 지었다(실패를 먼저 확인 → 구현 → 통과). 현재 **1,309개 테스트(42파일)** 그린, `tsc --noEmit` 0건 · `next build` 통과 · GitHub Pages 정적 export 빌드 통과.

층	테스트	무엇을 잠갔나
본편 시뮬 코어 (<code>src/sim</code>)	465 (20파일)	아래 표
본편 화면·클라이언트 (<code>simHud</code> · <code>useSimClock</code> · <code>lib/storyteller</code>)	238 (4파일)	금액 표기 단일 함수 · 시계 · 경고 스택·체크리스트·인스펙트 카드 등 표시 판정 전부 (순수 함수라 DOM 없이 거른다) · LLM 실패 7갈래가 전부 폴백으로 강등
이전 판 (<code>src/game</code>)	606 (18파일)	수용 판정 4종 사유 · 하드락 불변식 · 대사가 판정을 못바꿈 · 실명 토큰 가드

본편 코어가 잠근 것들 — 전부 "이 게임이 하려는 말"의 형태를 한 불변식이다.

파일	무엇을 잠갔나
<code>week.test.ts</code> (36)	주간 결산의 부호 불변식 I-B1 (응급을 최대한 받아도 필수과는 적자) · 엔딩 3종의 우선순위(돈 → 사람 → 시간)와 경계
<code>patientFlow.test.ts</code> (53)	도착 스트림의 시드 결정론 · 좌석 계약(의자 1개 = 좌석 1개) · 과 분포가 좌석수에 안 흔들림
<code>needs.test.ts</code> (37) · <code>fatigue.test.ts</code> (22)	피로 곡선의 시간 분할 불변식(하루를 어떻게 쪼개도 같은 피로) · 굶주림 감속
<code>events.test.ts</code> (29)	이벤트 4종의 전제 가드레일 (병상 0에 대량 응급이 안 떨어진다) · 배율이 실제로 곱해지는지 · 폴백 디렉터 결정론
<code>emergency.test.ts</code> (28)	배후과 없으면 하드락 · 응급 강도의 포화 관계(격리 조건 명시)
<code>resignation.test.ts</code> (20)	통지와 집행이 같은 명단 (주중에 본 「떠날 사람」과 실제로 떠나는 사람이 같다)
<code>narrative.test.ts</code> (22)	폴백 문장이 전 종류·전 엔딩에 존재 (LLM이 없어도 빈칸이 안 생긴다) · 조사 보간 함정

핵심은 순서다 — **게임의 논지를 지탱하는 불변식을 LLM을 붙이기 전에 코드로 먼저 증명**했다. LLM은 이 잠긴 코어 위에서만 논다. 특히 `narrative.test.ts` 가 "폴백 문장이 모든 자리에 있다"를 잠근 것이 스토리텔러를 붙일 수 있게 한 전제다 — **폴백이 먼저 완성되지 않으면 LLM은 없는 게 아니라 의존이 된다.**

돌연변이로 검증한다 — 테스트가 통과한다고 그 테스트가 무언가를 지키는 건 아니다. 그래서 이 저장소는 규칙을 임시로 훼손해 테스트가 **실제로 깨지는지** 확인하고 되돌리는 절차를 커밋마다 돌렸다. 실례: `eligible` 검증 제거 → 2건 사살 / 호출 상한 제거 → 3건 사살 / 타임아웃 `abort` 제거 → 1건 사살. 랜딩 스왑에서는 **라우트 표가 이 변경을 검증하지 못한다**는 것을 돌연변이로 발견했다(/ 를 옛 게임으로 되돌려도 라우트 표가 완전히 동일했다) — 판별력이 있었던 것은 export된 HTML의 마커 대조뿐이었고, 그것만 뒤집혔다.

3-3. 리서치 → 도메인 반영 — AI가 낸 안을 사람이 검증·기각한 로그

AI를 아이디어 뱌는 기계로 쓰지 않고, AI가 낸 것을 다른 AI들과 사람이 반증하게 했다.

- **PR #10** — 다중 에이전트 리서치 + 적대적 검증으로 게임 전제(STEMI·응급실 뽕뽕이)를 실제 통계로 팩트체크 → 방어 가능한 것만 팩트시트로.
- **PR #11** — 그 리서치가 도메인 모델 자체를 알아엿었다: "지배 병목은 병상 없음이 아니라 배후진료 불가"라는 근거로, 뭉뚱그린 onCallSpecialties 를 hasErOnCall (초기 수용) + backupCare (최종치료)로 분리하고 거절 사유를 4종으로 재설계.
- **PR #18** — 필수과 소송·방어진료 리스크의 "부호"를 5갈래·적대 검증으로 확인(검증 불가 수치는 배제, 방향만 채택).

이 세 PR이 보여주는 건 "AI가 만들어줬다"가 아니라 "AI 산출물을 어디서 신뢰하고 어디서 기각했는지"의 판단 로그다. 디렉터의 일은 생성이 아니라 이 취사선택이다.

3-4. 남의 패턴을 채택하지 않기로 한 판단 — LLM Wiki 대조 (PR #36)

우리는 LLM Wiki를 구현하지 않았다. 대조해보고 왜 이 도메인엔 안 맞는지 알아냈다.

Andrej Karpathy가 2026-04에 제안한 LLM Wiki는 "지식을 RAG처럼 매 질문마다 재발견하지 말고, LLM이 마크다운 위키를 소유·유지해 한 번 컴파일하라"는 패턴이다(3층: raw sources / wiki / schema, 3 op: ingest / query / lint). 이 저장소는 겉보기에 그것과 닮았다 — 상호링크된 마크다운 문서군, LLM이 쓰고 사람은 읽는 소유 구조, 세션 시작 혹은 frontmatter에서 재생성하는 자동 인덱스, 함정을 흑으로 승격시키는 사다리(§3-1). 그래서 대조해봤다.

결과: 아니다. 46에이전트 워크플로우(조사 5 → 매핑 → 3렌즈 적대검증 → 구멍분석)로 9개 요소를 대조한 결과 — **strong 0 / partial 1 / stretch 6 / 명시적 부재 2.** 검증 전 강도가 한 칸도 유지되지 못하고 전부 하향됐다.

Karpathy 요소	우리 것	적대검증 후
schema	글로벌 CLAUDE.md (259행)	partial — 형식·소유권은 부합하나 규율 대상이 위키가 아니라 git-TDD
wiki / log.md / index.md / ingest / raw-sources / cli-tools	research 4종 · changeLog · README 표 · 리서치 워크플로우 등	stretch ×6
query · lint	—	없음

원인은 게으름이 아니라 트리거의 방향이다. Karpathy 패턴의 전제는 소스가 도착하는 것(source-push)이다 — 기사를 떨구면 LLM이 읽고 위키 10~15장을 갱신한다. 우리 트리거는 반대다: 코드가 근거를 필요로 할 때 리서치를 발주한다(feature-pull). 그래서 기존 페이지를 재검토할 계기가 원리적으로 생기지 않고, 지식이 문서가 아니라 코드로 굳는다.

증거 넷 — 전부 이 저장소의 공개 이력에서 확인 가능하다:

1. **claude-docs/learning-notes.md**의 생애. 글로벌 규칙이 "필수 셋업 1번"으로 못박은 유일한 지식 축적 페이지가 부트스트랩에 빈 골격으로 태어나 22커밋 동안 한 줄도 못 쌓고(93f18ea → aba6d77 , 내용 변경 0건) PR #22에서 "이 프로젝트 미사용"으로 삭제됐다. 규칙이 없어서 안 쌓인 게 아니라, 규칙이 있는데도 안 쌓였다.

2. **PR #18** — 29에이전트를 돌리고 총 2파일 커밋. 기존 리서치 3종 갱신 **0건**.
3. **PR #36이 고친 것 자체** — 리서치의 지배 병목 교정이 **코드로는 흘러갔지만**(`adjudicate.ts`의 `NO_BACKUP_CARE`, PR #11) **문서로는 안 갔다**. `game-concept.md`는 부트스트랩 이후 **35커밋 무갱신**이라 게임 1막(설립 위저드·하루 자리 제한·7일 달력) 전체를 모르고 있었다.
4. **그리고 진단이 예측한 실패가, 진단하던 PR에서 그대로 일어났다**. PR #36의 lint는 **stale한 base**(#33 시점)에서 돌아, 그 사이 머지된 #34·#35를 모른 채 120에이전트가 낡은 코드를 읽었다 → **낡은 문서를 고치면서 #35가 이미 폐기한 개념**("분기 손익")을 새로 써넣었다(13건 중 3건 오염, 사후 발견·재작성 → T-038). 적대 검증 3렌즈도 못 막았다 — 검증은 "트리 안에서의 정합성"만 봤지 "트리 자체가 최신인가"는 아무도 보지 않았다.
- 그래서 무엇을 했나 — **채택이 아니라 계측**. 패턴을 이식하는 대신 그 패턴이 짚어준 결함 하나를 실제로 고쳤다 (PR #36, 120에이전트 lint → **38건 중 16건 기각**). 반대로 **채우지 않기로 한 것도 명시했다** — `docs/raw/` 신설(저작권·비용 대비 무의미), ingest 규칙 성문화(소스가 안 오는데 규칙만 넣으면 learning-notes 실패의 재연), 위키 검색 도구(Karpathy 본인이 optional, 우리 규모엔 `ripgrep`으로 충분). **도구를 위한 도구를 만들지 않았다**.

왜 이게 디렉팅인가 — 유행하는 AI 패턴을 가져다 붙이는 건 누구나 한다. 요점은 **붙이지 않기로 한 근거를 데이터로 만든 것이다**. "우리도 LLM Wiki를 한다"고 쓰는 편이 유리해 보이지만 그 주장은 PR #18의 2파일 커밋 하나로 뚫린다. 그래서 위 표의 빈 칸(query·lint)은 stretch로 채우지 않고 **빈 칸으로 뒀다** — §5의 '감수' 원칙(없는 걸 있다고 부르지 않기)이 여기에도 그대로 적용된다. 남의 패턴에 부분 점수를 구걸하는 대신 우리가 실제로 한 것에 정확한 이름을 붙였다: **이건 LLM Wiki가 아니라 "LLM이 운영하는 개발 워크플로우"다**. 무엇을 쓸지 정하는 것만큼 무엇을 안 쓸지 정하는 것도 디렉터의 일이고, 후자는 대개 기록에 남지 않는다. 그래서 남겼다.

4. 게임 속 AI — 사람이 떠나는 자리와 판이 끝나는 자리

결말은 "무엇이 죽었나"를 **설명하지 않는다**. 팩트만 라벨+숫자로 병치하고, 플레이어가 스스로 잇게 한다("보여주지 말고 겪게"). 그 원칙은 LLM이 붙은 뒤에도 안 바뀐다 — **지표는 언제나 코드가 확정하고, LLM은 그 지표를 문장으로 옮길 뿐이다**.

- **사직 편지** — 떠나는 의사의 이름·특성·포화로 마감한 날 수가 들어간다. 이 값들은 전부 세계에서 파생되고 LLM에 **입력으로만** 간다. 시스템 프롬프트는 "떠나는 것이 「내과 1명」이 아니라 사람 하나임이 드러나게" + "원망도 훈계도 없이"를 지시한다. 편지의 머리줄(누가 떠나는가)은 LLM이 못 만진다 — 세계 파생 사실이라 본문만 교체된다.
- **에필로그** — 엔딩 3종(돈이 바닥남 / 사람이 바닥남 / 기간 종료)과 주차·이탈 수·사직 명단·금고가 입력이다. 금고는 **이미 포맷된 문자열**로 넘긴다 — 원본 숫자를 넘기면 LLM이 「3200만원」이라 쓰고 폴백은 「3,200만원」이라 써서 **두 결말문이 서로 다른 단위를 말하게 된다**. (리뷰에서 실제로 잡힌 우회로다.)
- **폴백 원고가 먼저 있다** — 사건 연출문·사직 편지·에필로그 세 자리 모두 사전 작성 한국어 문장이 카탈로그(`narrative.ts`)에 상주하고, 그것이 **전 종류·전 엔딩에 존재함을 테스트가 잠근다**. LLM 문장은 도착하면 갈아 끼우는 것이고, 안 오면 그냥 안 갈아 끼운다.

톤 가드레일은 프롬프트에도, 폴백 원고에도 같이 걸려 있다 — "특정 직군·집단을 비난하지 않고 구조적 공백만 근거". 한쪽에만 걸면 LLM이 죽는 날과 사는 날의 게임이 서로 다른 말을 한다.

5. 안전 · 정확성 · 비용

- **의학적 정확성** — 게임 내 수치는 각색이되 **부호·대소(적자↔흑자, 지배 병목의 방향)**는 근거를 지킨다. '감수'라 칭하지 않고 **출처 각주 + 게임적 각색 고지**로 처리(검증 불가 수치는 출처 명시 범위로만). 근거: [essential-care-economics](#) · [essential-care-litigation-risk](#) · [medical-system-grounding](#) · [stemi-factsheet](#).
- **톤 가이드라인** — "특정 직군·집단을 비난하지 않고 **구조적 공백만 근거**"를 결정론 풀백 원고와 LLM 시스템 프롬프트 **양쪽에** 고정(\$4). 프롬프트에는 "**의학·법률 자문이 아니라 게임 각색이다**".*플레이어를 탓하거나 훈계하지 않는다"*도 함께 박혀 있다.
- **키 안전** — LLM 키는 **서버 전용**이다. `NEXT_PUBLIC_` 접두사를 붙이지 않아 브라우저 번들에 실리지 않고, 게임은 자기 서버의 프록시 라우트(`/api/storyteller`)만 부른다. 응답 본문은 **로그에도 안 찍는다**(로그가 곧 유출면 — 사용량 통계만 찍는다).
- **비용 안전** — **코드 안 세 겹, 코드 밖 두 겹**.
 - 코드 안: 판당 호출 상한 **10회**(실패한 호출도 소모로 센다 — 죽은 라우트를 만난 판이 아침마다 10초씩 멈추는 것을 막는다) · SDK 재시도 **0회**(기본값 2는 9초 타임아웃을 실제 28초로 만든다 — 리뷰 실측 28.45초) · 브라우저 `Origin` 이 허용 목록이나 같은 오리지인이 아니면 **403**.
 - ⚠ **Origin** 검사는 **CORS이지 인증이 아니다**. `curl -H Origin:` 한 줄로 위조된다 — 막는 것은 **남의 페이지가 브라우저에서 우리 지갑을 쓰는 경로뿐**이다. **최종 방어선은 코드 밖 대시보드 둘**이다(Vercel Firewall의 rate-limit 룰 + Anthropic 콘솔 지출 상한). 이걸 "충분히 막았다"고 쓰지 않고 한계를 그대로 적는 것이 \$5의 원칙이다.
- **API 비용 부담 주체** — 대회 FAQ에서 확인하지 못했다(문의처: info@nhn-nan.com). 그래서 **키가 없어도 게임이 완주되도록** 만든 것이 설계의 전제였고, 실제로 그렇다 — 심사자가 키 없이 열어도 「기본 서사」로 12주를 끝까지 돌 수 있다.

6. 실제 프롬프트 — 개발 과정의 지시 로그

여기 실린 것은 **개발 세션에 실제로 입력된 원문**이다(2026-07-15 ~ 07-22, 세션 로그 전수 파싱). 오타·구어체를 고치지 않고 그대로 실는다 — 다듬으면 그 순간 "사후에 쓴 문서"가 되기 때문이다.

6-0. 전수 통계 — 무엇을 지시하고 무엇을 위임했나

7일간 프로젝트·워크트리 8개 세션에 입력된 사용자 프롬프트를 전부 추출했다(도구 알림·시스템 주입 제외).

항목	실측
총 프롬프트	257개 (7일, 총 18,347자)
길이 중앙값 / 평균	21자 / 71.4자
20자 이하 — "머지하자"."진행해"급 승인	128개 (49.8%)
100자 이상 — 방향을 바꾼 지시	45개 (17.5%)

절반이 20자 이하다. 이건 게으름이 아니라 위임 구조의 지표다 — 규칙(§3-1)과 잠긴 코어(§3-2)가 서 있으면 대부분의 턴은 승인으로 끝나고, 사람의 언어는 **방향이 갈리는 45개 지점**에 몰린다. 아래 6-1~6-3은 그 45개에서 골랐다.

6-1. 디렉팅 프롬프트 5선 — 지휘가 실제로 일어난 자리

① 심사 기준을 다시 읽고 문서의 축을 뒤집은 지시 (7/16)

"사전 과제 제출물에서 AI 활용 기술 문서에 관한 내용이 게임에 AI를 어떻게 녹였냐가 아니라 AI를 활용해서 어떻게 이 게임을 만들었냐를 보는거 같거든? 지금 넌 이 평가 기준을 이미 알고있어? 뭔가 내가 경험한 느낌은 AI를 어떻게 게임 속에서 하나의 기능으로 활용할지에 무게를 두는거 같아서,"

→ 이 문서의 §0(디렉팅=주 / 게임 속 AI=종)이 여기서 나왔다. 그 전까지 AI는 "게임에 넣을 기능"으로 다뤄지고 있었다. 사람이 요강을 다시 읽고 축을 바꿨다.

② AI 해커톤에서 '눈에 보이는 AI'를 스스로 삭제한 결정 (7/18)

"1. 뽕뽕이 경험과 대화형은 사실 아무 상관이 없다고 생각해. 왜냐하면 사실 다른 병원에 환자 받아달라고 전화할 때 어떻게 말을 하냐가 중요하지 않잖아. 서비스업도 아니고. 그냥 기존 시스템을 일단 유지하되 거기서 사용자가 대사를 넣을 수 있던 박스만 삭제해. 2. 라이브로는 뒷단에서 AI가 돌아가는걸 보여주기 힘들겠지. 이걸 문서로 강조하고 라이브 동영상의 AI가 노출되지 않는다는 단점은 감안하자."

→ 자유 텍스트 설득 입력은 **영상에서 AI가 가장 잘 보이는 자리**였다. 그걸 "현실의 전원 거절은 화술로 뒤집히지 않는다"는 이유로 지웠고, 심사에서 불리할 수 있음을 알면서 감수했다. §2의 권한 경계가 문서상의 다짐이 아니라는 증거가 이 프롬프트다. 이를 전 같은 방향의 선행 결정도 있었다 — "대화 LLM은 사실 없어도 될거같은 하거든. [...] plan에 넣어서 발전 가능성으로만 기록해두고 일단은 우선순위에서 많이 뒤로 미뤄도 될거같아."(7/16)

③ AI 산출물의 근거를 의심한 2연타 (7/16)

"혹시 지금 게임을 만드는데. 현재 대한민국 의료 시스템에 대한 문제점을 먼저 파악하고 게임의 방향성을 잡은거야? 아니면 그냥 막연히 진행하고 있는거야??"

→ "실제로 리서치 하고 구멍 매우자. 이 게임은 의도가 중요한 게임인데 리서치 없이 진행하면 나중에 의도에 타격이 있을 가능성이 있을거같아."

→ 첫 문장이 **AI가 그럴듯하게 만든 것과 근거가 있는 것을 구분**하라는 요구다. 이 두 턴이 §3-3의 리서치 축(PR #10-#11-#18)을 열었고, 그 결과 도메인 모델의 지배 병목이 **병상 없음** → **배후진료 불가**로 교체됐다.

④ AI의 자기 규칙 준수를 감사한 질문 (7/20)

"근데 요즘들어 트러블슈팅 작성이 거의 없는데 트러블이 없어서 작성을 안한거야 아니면 트러블슈팅 작성을 너가 생각을 안하고 있는거야? 왜냐하면 저번에 넌 트러블슈팅을 작성 안하고 메모리를 우선적을 작성했던적이 있거든."

→ "안 일어난 것"과 "AI가 못 알아챈 것"을 구분해서 물었다. **후자였다** — 실측 결과 T-054 이후 8 PR 동안 트러블슈팅 0건. 서버에이전트가 디버깅을 흡수하면서 진행 ledger가 **완료**만 추적하고 **만난 함정**을 안 남긴 구조적 공백

이었고, 이 질문이 T-055 등재와 CLAUDE.md 의 「SDD 종료 trap 스위치」 규칙을 낳았다. §3-1의 감사(준수 100%집계 0회)와 같은 계열의 개입이다.

⑤ AI 사용 자체를 계속 대상으로 만든 규칙 신설 (7/16)

"Claude.md에 규칙을 하나 추가하자. 이 프로젝트에만 적용되는 규칙인데 쓸모있다 싶으면 승격할거야. 작업 중에 사용된 스킬, plugins을 깃 커밋 메시지에 명시해둬. 그렇게해서 해당 스킬이 얼마나 자주 사용되는지, 또는 있는데 사용되지 않는 스킬은 뭔지. 그 스킬을 통해서 어떤 이점을 봤는지를 파악하는데 도움을 얻기 위함이야. 기술적으로 가능해?"

→ §3-1이 감사한 그 규칙의 발주 프롬프트다. "쓸모있다 싶으면 승격할거야"라는 조건부 도입이 곧 프로젝트 → 글로벌 → 혹 하드가드 사다리의 첫 칸이었다.

6-2. 같은 벽을 네 번 세우다 — show-don't-tell

AI는 친절하게 설명하려는 기본 성향이 있고, 그 성향은 이 게임의 논지("겪게 하고 설명하지 않는다")를 조용히 갉아먹는다. 한 번의 지시로는 안 잡혀서 네 번 같은 벽을 세웠다.

날짜	원문(발췌)	무엇을 막았나
7/16	"지금 게임을 보면 구조를 바꿨다면 더 좋았을 거라는걸 직접적으로 보여주고 있거든. 그냥 글로 보여주잖아. 이거 없애자. [...] 이렇게 대놓고 구조적입니다 라고 글로 보여주고 싶지 않아. 이건 좋은 게임이 아니야."	결말의 해석 카피 → §4 "해석 카피 0"의 뿌리
7/17	"수익 예상이 높은지 낮은지, 소송 리스크가 큰지 적은지는 명시적으로 보여주지마. 플레이어가 경험을 통해서 알도록 유도하게."	개원 위저드의 정답 표시(고르기 전에 답을 알려주는 UI)
7/19	"필수의로 단어 설명은 좋은데, 추가적으로 그 단어와 현재 의료시스템의 문제까지 엮어서 설명하는건 빼. 단어설명만 사용자에게 전달하라는거야."	용어 툴팁에 논평이 없히는 것
7/20	"병원을 키울 수 있도록 장치를 추가하자. 단, 대한민국 의료 시스템의 딜레마를 생각하고 시스템을 만들어야 해. 병원 규모가 커진다고 해서 의료시스템에 문제가 사라지지 않는거잖아."	성장 재미가 메시지를 해소해버리는 설계 → 제로섬 재투자 루프

마지막 것은 방어가 아니라 발주 조건이다. "성장을 넣되 성장으로 문제가 풀리면 안 된다"를 기능 요청과 같은 문장에 넣었고, 그래서 전국 유한 인력 풀(돈이 있어도 못 뽑음)이 나왔다.

6-3. 오케스트레이션 발주 — 24자가 3세션 삼각검증이 되기까지

"후보 구현 우선순위 뽑기 작업을 프롬프트로 줘 / 세 세션에서 진행하게" (7/18, 24자)

이 짧은 지시의 요구는 두 겹이다. (1) 프롬프트를 AI가 쓰게 하고, (2) 그 프롬프트를 서로 모르는 3개 세션에 독립으로 돌려 교차검증한다. 산출된 지시서(1,933자)는 채점축 4개(메시지 기여·메커닉 적합·구현비용·팩트/톤 안전)와 가중 공식 $M \times 2 + F + C + S$, 그리고 "다른 세션 결과를 절대 참고하지 말 것 / 출력 형식을 바꾸지 말 것"(병합 가능성 확보)을 못박았다.

⚠️ **정확한 귀속** — 그 1,933자 지시서는 **사람이 아니라 AI가 작성했다**. 사람이 한 것은 "프롬프트로 줘 / 세션에서" 24자와, 세 결과를 받아 병합·판정한 것이다. 없는 걸 있다고 부르지 않는다(\$5) — 이 파이프라인의 이름은 "**사람이 검증 구조를 발주하고, AI가 지시서를 쓰고, 사람이 결과를 병합한다**"이지 "사람이 정교한 프롬프트를 썼다"가 아니다.

같은 계열의 판단 프롬프트 둘을 덧붙인다.

- **도입하려던 AI 패턴을 스스로 철회** (7/17) — "LLM Wiki를 구축하기 위해서 이런저런 작업을 했는데, 내가 원하는게 LLM Wiki가 아니었던거 같아. [...] 이 아이디어에 허점 파악해봐. 일단 당장 내 머리에 떠오른 허점은 링크를 AI한테 맡기는데, 여기서 잘못된 판단으로 인해 연결 되어야 하는게 연결되지 않는 문제가 있을 수 있다고 생각해." → 하루 전에는 "NHM 해커톤 평가사항인 AI 활용도 측면에 어필하고 싶은게 생겼어. LLM Wiki를 활용했다는걸 넣고 싶거든." (7/17)이었다. **어필용으로 넣으려던 패턴을 직접 철회하고, 자기 대안의 허점까지 AI에게 먼저 반증시켰다** → §3-4.
- **근거가 흐리면 구현을 멈춤** (7/20) — "현실에서 내과 진료 과목 상대로 소송이나 언론에 논란으로 다뤄진적이 있어?" → (팩트체크 결과 회색지대) → "내과는 애매한 부분이 많네. 피부과처럼 안전한 느낌을 내과에 줄 생각은 전혀 없거든. 일단은 법적 리스크를 구현하지는 말되, 나중에 좀 더 리서치하고 구현하게 문서로 남겨는 놔." → 근거의 부호가 안 잡히면 **기능을 넣지 않고 보류로 남긴다**. §5의 원칙이 실제 기능 결정에서 작동한 사례.

6-4. 게임 런타임 로그 — 실측

위 6-1~6-3은 **개발 과정(B축)의 지시 로그**다. 여기는 **게임 런타임(A축)** — 게임이 LLM에게 보내는 프롬프트와 그 응답의 자리다. 추정치는 적지 않는다. 아래는 전부 실제로 썬 보고 받은 값이다.

✅ 실측된 것 ① — 강등이 실제로 작동한다

"AI가 죽어도 게임은 완주된다"는 이 문서의 핵심 주장이고, 그걸 증명하는 실측은 실호출보다 오히려 이쪽이다. 로컬 dev 서버에 키 없이 요청했을 때:

```
POST /api/storyteller → 503 {"error":"NO_KEY"} (44ms)
클라이언트: 비200 → null
화면: HUD 배치 「기본 서사」 · 사건 선택은 폴백 디렉터 · 연출문은 narrative 카탈로그
결과: 게임은 아무 변화 없이 계속 돈다 (흰 화면·빈 문장·에러 토스트 0)
```

44ms는 실호출 지연이 아니라 **강등에 걸린 시간**이다. 키 없는 배포본에서 플레이어가 체감하는 지연이 그만큼이라는 뜻이고, 이게 GitHub Pages 제출본의 기본 동작이다.

✅ 실측된 것 ② — 프록시 보안·재시도

리뷰에서 지적된 무인증 공개 프록시 문제를 고친 뒤, dev 서버(데미 키)로 네 경우를 직접 썬 확인했다.

요청	결과
POST · <code>Origin</code> 없음	403 FORBIDDEN_ORIGIN
POST · <code>Origin</code> 이 남의 사이트	403 FORBIDDEN_ORIGIN
POST · <code>Origin</code> 이 허용 목록	502 UPSTREAM (상류 401을 잡아 CORS 헤더째 강등)
POST · <code>Origin</code> 이 같은 오리진	502 UPSTREAM — 자기 자신을 403 으로 막지 않음을 확인
OPTIONS (프리플라이트)	204

서버 로그에는 `[storyteller] director 401 ...` 만 남고 **키는 안 찍힌다**.

그리고 재시도 상한: SDK 기본값(`maxRetries: 2`)에서 타임아웃이 나면 9초 타임아웃이 **실제로는 3회 · 28.45초**가 되는 것을 실측했다. 클라이언트는 10초에 끊으므로 남은 약 20초는 **응답을 아무도 안 받는데 돈만 나가는 구간**이다. `maxRetries: 0` 으로 단았다.

✅ 실측된 것 ③ — 실호출 지연·토큰·비용 (2026-07-28)

키를 붙이고 **모델 3종 × 작업 3종**을 실제로 돌렸다. 로컬 dev · SDK `timeout: 9초` · `maxRetries: 0`.

모델	director	letter	epilogue
<code>claude-opus-5</code>	200 / 8.1초 (in 1076 · out 113 · thinking 0)	502 — 타임아웃 9,045ms	502 — 타임아웃 9,025ms
<code>claude-sonnet-5</code>	200 / 4,271ms (in 1076 · out 96)	200 / 4,163ms (in 553 · out 148)	200 / 3,641ms (in 587 · out 143)
<code>claude-haiku-4-5</code>	400	400	400

`claude-haiku-4-5` 의 400은 셋 다 같은 사유다 — *"This model does not support the effort parameter."* 이 라우트는 항상 `effort: 'low'` 를 보내므로(\$2) 하이쿠는 애초에 못 쓴다.

코드 기본값을 `claude-opus-5` → `claude-sonnet-5` 로 바꾼 근거가 이 표다. 최상위 모델이라 기본값으로 삼았는데, 토큰이 적은데도 모델 자체가 느려 **세 작업 중 둘이 항상 폴백으로 강등됐다** — *작동하지 않는 기본값*이었다. 폴백이 튼튼해서(실측 ①) 게임은 멀쩡히 완주했고, 그래서 **실호출을 돌려 보기 전까지 아무도 몰랐다**.

프로덕션 실측 — 요청 JSON ↔ 응답 원문

`LLM_MODEL=claude-sonnet-5` 로 재배포한 뒤 <https://hospital-sim-ashy.vercel.app> 에 같은-오리진 `origin` 헤더로 3작업을 쏘다. 셋 다 200이다.

director — 4,359ms

```
{"week":3,"day":2,"eligible":["MASS_CASUALTY","EPIDEMIC","NEARBY_CLOSURE"],"doctors":3,"treasuryManwon":12000,"turnedAwayTotal":2,"wards":1}
```

```
{"event":"NONE","narration":"별다른 사건 없이 평온한 하루가 지나갔다. 병원은 평소와 같은 속도로 환자를 맞이했다."}
```

letter — 4,711ms

```
{"name":"김서준","deptLabel":"내과","saturatedDays":4,"traits":["완벽주의","밤샘 체질"],"week":5}
```

4일 내내 포화 상태였던 병동을 뒤로하고, 김서준입니다. 완벽하게 끝내고 싶었던 일들이 자꾸 미완으로 쌓여 가는 걸 지켜보는 게 힘들었습니다. 밤을 새우는 건 익숙했지만, 그 밤이 끝나지 않는 것 같습니다. 그동안 함께해주셔서 감사했습니다. 부디 다들 건강하시길 바랍니다.

epilogue — 3,301ms

```
{"ending":"NO_PEOPLE","week":9,"leftCount":14,"resignedNames":["김서준"],"treasuryManwon":3200}
```

9주차, 병동에 남은 사람은 열넷. 김서준이 사직서를 내고 떠난 자리는 끝내 채워지지 않았다. 통장에는 3,200만 원이 남아 있었지만, 그 돈으로 살 수 없는 것이 있었다. 사람. 병원은 문을 닫지 않았다. 다만 그 안을 채울 사람이 더 이상 남아 있지 않았을 뿐이다.

세 응답 모두 수치를 지어내지 않았다 — 9주차·열넷·3,200만 원·김서준은 전부 요청 JSON에 있던 값이다. 그게 이 설계의 요점이다(§2): 판정과 지표는 코드가 확정해 넘기고, LLM은 그걸 연기한다. director가 고른 NONE도 eligible 목록 안에서만 고를 수 있는 enum 값이다.

✅ 실측된 것 ④ — 실플레이 중 게임이 스스로 부른 호출 (2026-08-03)

위 실측 ③은 합성 요청(같은-오리진 헤더를 붙인 직접 호출)이었다. 이번에는 프로덕션 배포본을 처음부터 끝까지 실제로 플레이하면서(12주 완주 1회 + 검증 런 1회) 게임 클라이언트가 자연스럽게 보낸 트래픽을 네트워크 레벨에서 관측했다.

게임이 보낸 director 호출 원문 — 하루를 넘길 때마다 1회, 브라우저가 스스로 보낸 것이다:

```
{"task":"director","state":{"week":1,"day":3,"eligible":["EPIDEMIC","NEARBY_CLOSURE","LAWSUIT"],"doctors":3,"treasuryManwon":50000,"turnedAwayTotal":5,"wards":0}}
```

```
{"event":"NONE","narration":"별다른 소식 없이 평온하게 하루가 지나갔다."}
```

이를 연속 관측에서 LLM은 둘 다 NONE(오늘은 사건 없음)을 골랐고, narration은 매번 다른 문장이었다(전날은 "별다른 특이사항 없이 조용한 하루가 지나갔습니다. 병원은 평소와 같은 속도로 환자를 맞이했습니다."). 요청의

eligible 에 LAWSUIT 이 올라온 것도 보인다 — 응급 회차가 쌓인 상태라 **결정론 코드가 후보에 올랐고**, 고르는 것만 LLM이다. "고를 수 있는 것의 목록은 코드, 고르는 것은 AI"라는 §2의 분업이 실제 트래픽에 그대로 찍혀 있다.

「AI 서사」/「기본 서사」 배지의 시간 계약도 **실플레이에서 재현됐다**. 마감 창이 뜨자마자 [다음 날]을 누르면(응답이 1~2초 뒤에 도착) 그 아침은 「기본 서사」로 진행되고, 몇 초 두었다 누르면 「AI 서사」로 바뀐다 — *도착해 있으면 LLM의 선택, 아니면 폴백, 기다리지 않는다*가 화면 배지로 관측 가능하다는 뜻이다. 12주 완주 런에서도 같은 사건(인근 병원 폐업)이 판 내내 **서로 다른 문장 4종**으로 왔고, 진행을 빠르게 연타한 구간은 「기본 서사」로 내려갔다 — 판당 상한·방화벽 레이트리밋(600초당 10회)이 걸려도 게임이 에러가 아니라 폴백으로 강등된다는 아래 운영 안전망 절의 주장이 플레이 화면에서 그대로 확인된 것이다.

비용 — 판당 약 40원

Sonnet 5 도입가 기준(\$2 / \$10 per MTok, 2026-08-31까지):

작업	입력	출력	1회 비용
director	1,076	113	\$0.0033 (약 4.6원)
letter	553	148	\$0.0026 (약 3.6원)
epilogue	587	143	\$0.0026 (약 3.6원)

판당 호출 상한은 10회(§2)이므로 한 판의 LLM 비용 상한은 **약 40원**이다. 현재 크레딧 잔액 US\$3.45로 **약 120판** 분량 — 심사 기간 동안 공개 배포본이 계속 켜져 있어도 소진되지 않는 규모다.

운영 안전망은 코드 밖 대시보드 둘이다(§2의 "최종 방어선"): **Vercel Firewall rate-limit** 룰(/api/storyteller · 600초당 IP별 10회) + **Anthropic 월 지출 한도 \$10 · 자동충전 꺼짐**. 상한을 넘기면 게임은 에러가 아니라 폴백으로 강등된다.

그리고 애초에 폴백일 수밖에 없는 자리들 — 혼재는 의도다

실호출이 불어도 게임의 문장이 100% LLM이 되지는 **않는다**. 그렇게 설계했다.

- **1주 1일차 아침은 구조상 항상 폴백이다**. 사건은 아침 전이(어제 → 오늘)에 붙는데 첫날은 그 전이가 없다. 첫날을 유예일로 둔 것은 밸런스 결정이고, 그 부작용으로 첫 화면의 서사는 언제나 결정론이다.
- **사직 편지는 한 주에 한 명분만 LLM이다**. 세 명이 떠나는 주에 세 번 부르면 판당 상한 10회가 한 주에 소진되고, 그렇다고 한 번에 몰아 쓰게 하면 편지가 **명단 낭독**이 된다. 나머지 사람의 편지는 폴백 원고가 쓴다.
- **판당 10회를 넘기면 그 뒤로는 전부 폴백이다**. 12주 완주에 아침 전이는 84회다.

즉 한 판의 서사는 **LLM 문장과 폴백 문장이 섞인 상태가 정상**이다. 이걸 결함으로 숨기지 않고 화면의 배지(「AI 서사」/「기본 서사」)로 **플레이어에게 그대로 보여주는 것**이 이 설계의 입장이다 — AI가 어디까지 관여했는지를 감추면, "AI를 어디서 끊었는가"라는 주장은 검증할 수 없는 말이 된다.

7. 외부 에셋 · 오픈소스 출처

구분	항목	비고
프레임워크·툴	Next.js 16 (App Router), React 19, TypeScript, Tailwind CSS 4, vitest	각 오픈소스 라이선스 준수
AI SDK	<code>@anthropic-ai/sdk</code>	스토리텔러 프록시 라우트 전용(서버)
AI	Anthropic Claude — 개발(Claude Code) + 런타임 API(<code>claude-sonnet-5</code> · 사건 선택·연출문·사직 편지·결말문)	키는 서버 전용
에셋	UI는 커스텀 텍스트·타일 렌더 중심(외부 이미지·폰트·사운드 없음)	외부 에셋을 도입하면 여기에 출처·라이선스를 명시한다

관련 문서

 [시각화·PDF판 — 디렉터의 운영체제](#) (라이브 아티팩트 · 최종 브라우저 인쇄로 PDF)

[game-concept](#) · [submission-plan](#) · [plan](#) · [changeLog](#) · [troubleshooting](#)

문서 상태: 작업 초안 (2026-07-30 갱신 — §3-1 3차 집계 · §3-2 테스트 수 1,309/42로 갱신 · 간호사 축 반영). P7(8/3~8/7)에 §3-1 집계를 최종 확정한다.